

The Elements of Statistical Learning

統計的学習の基礎

nukui

2019 年 10 月 5 日

1 序章

2 教師あり学習の概要

2.1

K クラス分類問題の目標変数 t_k が、第 k 要素のみが 1 で他の要素は 0 である K 次元ベクトルによって表されているとする。予測結果 \hat{y} を全ての要素の和が 1 となるように正規化したとき、 \hat{y} の最大要素を持つクラスへの分類と $\|t_k - \hat{y}\|$ を最小化するクラスへの分類が等価であることを示せ。

\hat{y} の最大要素が第 j 要素 \hat{y}_j であるとする。

$$\begin{aligned} & \|t_k - \hat{y}\|^2 - \|t_j - \hat{y}\|^2 \\ &= \left\{ \sum_{i \neq k} \hat{y}_i^2 + (1 - \hat{y}_k)^2 \right\} - \left\{ \sum_{i \neq j} \hat{y}_i^2 + (1 - \hat{y}_j)^2 \right\} \\ &= \hat{y}_j^2 + (1 - \hat{y}_k)^2 - \hat{y}_k^2 - (1 - \hat{y}_j)^2 \\ &= 2(\hat{y}_j - \hat{y}_k) \geq 0 \end{aligned}$$

よって、 $k = j$ のとき、かつその時に限り、 $\|t_k - \hat{y}\|$ が最小値 $\|t_j - \hat{y}\|$ になることがわかる。以上より、 \hat{y} の最大要素を持つクラスへの分類 j と、 $\|t_k - \hat{y}\|$ を最小化するクラスへの分類が等価であることがわかる。

2.2

図 2.5 の試行の例においてベイズ決定境界を求めよ。

(青色クラス) 2 次元ガウス分布 $N((1, 0)^T, \mathbf{I})$ から生成された 10 個の平均ベクトル (青色クラス) を $\{m_1, m_2, \dots, m_{10}\}$ とし、2 次元ガウス分布 $N((0, 1)^T, \mathbf{I})$ から生成された 10 個の平均ベクトル (オレンジ色クラス) を $\{n_1, n_2, \dots, n_{10}\}$ とする。

2.2.1

$\{m_1, m_2, \dots, m_{10}\}$ と $\{n_1, n_2, \dots, n_{10}\}$ の値がすでにわかっていると仮定する。このとき、ベイズ決定境界上の点 x の条件は

$$\Pr(\text{青色} | x) = \Pr(\text{オレンジ色} | x)$$

となる。

$$\frac{\Pr(\text{青色} | x)}{\Pr(\text{オレンジ色} | x)} = \frac{\Pr(\text{青色} | x) \Pr(x)}{\Pr(\text{オレンジ色} | x) \Pr(x)} = \frac{\Pr(x | \text{青色}) \Pr(\text{青色})}{\Pr(x | \text{オレンジ色}) \Pr(\text{オレンジ色})}$$

$\Pr(\text{青色}) = \Pr(\text{オレンジ色})$ なので、結局、ベイズ決定境界の式は

$$\Pr(x | \text{青色}) = \Pr(x | \text{オレンジ色})$$

と表せる。10 個の平均ベクトルのどれが選ばれるかは等確率であり、 i 番目のベクトルが選ばれた時には、平均 m_i (または n_i) で、分散 $\mathbf{I}/5$ の 2 変数ガウス分布に従うので、ベイズ決定境界上の点 x の条件式は

$$\sum_{i=1}^{10} \frac{1}{10} \frac{\sqrt{5}}{2\pi} \exp\left\{-\frac{5(x - m_i)^T(x - m_i)}{2}\right\} = \sum_{i=1}^{10} \frac{1}{10} \frac{\sqrt{5}}{2\pi} \exp\left\{-\frac{5(x - n_i)^T(x - n_i)}{2}\right\}$$

と表される。

2.2.2

$\{m_1, m_2, \dots, m_{10}\}$ と $\{n_1, n_2, \dots, n_{10}\}$ の値が未知だと仮定した場合、観測された値を頼りに確率を計算することができる。 N 個の p 次元ベクトル x_i ($i = 1, \dots, N$) が青色の点として観測されていて、 y_i ($i = 1, \dots, N$) がオレンジ色の点として観測されているとする。平均 μ で、分散 σ の 2 変数ガウス分布の x における確率密度関数を $f(x; \mu, \sigma)$ と表すとすると、

$$\begin{aligned} & \Pr(x | \{x_1, x_2, \dots, x_N\}, \text{青色}) \\ &= \sum_{m_1, \dots, m_{10}} \Pr(\{m_1, \dots, m_{10}\} | \{x_1, x_2, \dots, x_N\}) \Pr(x | \{m_1, \dots, m_{10}\}) \\ &= \sum_{m_1, \dots, m_{10}} \frac{\Pr(\{m_1, \dots, m_{10}\}) \Pr(\{x_1, \dots, x_N\} | \{m_1, \dots, m_{10}\})}{\Pr(\{x_1, x_2, \dots, x_N\})} \Pr(x | \{m_1, \dots, m_{10}\}) \\ &= \sum_{m_1, \dots, m_{10}} \frac{\{\prod_{i=1}^{10} f(m_i; (1, 0)^T, \mathbf{I})\} \{\prod_{k=1}^N \sum_{j=1}^{10} \frac{1}{10} f(x_k; m_j, \mathbf{I}/5)\}}{\int \{\prod_{i=1}^{10} f(m_i'; (1, 0)^T, \mathbf{I})\} \{\prod_{k=1}^N \sum_{j=1}^{10} \frac{1}{10} f(x_k; m_j', \mathbf{I}/5)\} dm_1' \dots dm_{10}'} \Pr(x | \{m_1, \dots, m_{10}\}) \\ &= \int \left\{ \frac{\{\prod_{i=1}^{10} f(m_i; (1, 0)^T, \mathbf{I})\} \{\prod_{k=1}^N \sum_{j=1}^{10} \frac{1}{10} f(x_k; m_j, \mathbf{I}/5)\} \{\sum_{j=1}^{10} \frac{1}{10} f(x; m_j, \mathbf{I}/5)\}}{\int \{\prod_{i=1}^{10} f(m_i'; (1, 0)^T, \mathbf{I})\} \{\prod_{k=1}^N \sum_{j=1}^{10} \frac{1}{10} f(x_k; m_j', \mathbf{I}/5)\} dm_1' \dots dm_{10}'} \right\} dm_1 \dots dm_{10} \end{aligned}$$

となる。また、ベイズ決定境界上の点 x の条件式は

$$\Pr(x | \{x_1, x_2, \dots, x_N\}, \text{青色}) = \Pr(x | \{y_1, y_2, \dots, y_N\}, \text{オレンジ色})$$

と表される。これを計算機でいい感じに求めることができるのかどうか、知りませんが。。

2.3

式 (2.24) を導け。

$$d(p, N) = \left(1 - \left(\frac{1}{2}\right)^{\frac{1}{N}}\right)^{\frac{1}{p}}$$

p 次元空間の半径 r の球の体積を Cr^p とおく (C は定数)。半径 1 の球に N 個の点が均一に散らばっているとすると、原点に最も近い点 x が半径 r の中に入っている確率は

$$\begin{aligned} \Pr(X < r) &= 1 - \Pr(X \geq r) \\ &= 1 - \left(\frac{C - Cr^p}{C}\right)^N \\ &= 1 - (1 - r^p)^N \end{aligned}$$

よって、 X の中央値 d は $\Pr(X < d) = \frac{1}{2}$ となる境界なので、

$$\begin{aligned} 1 - (1 - d^p)^N &= \frac{1}{2} \\ \frac{1}{2} &= (1 - d^p)^N \\ 1 - d^p &= \left(\frac{1}{2}\right)^{\frac{1}{N}} \\ d &= \left(1 - \left(\frac{1}{2}\right)^{\frac{1}{N}}\right)^{\frac{1}{p}} \end{aligned}$$

以上より、 $d(p, N) = \left(1 - \left(\frac{1}{2}\right)^{\frac{1}{N}}\right)^{\frac{1}{p}}$ と求められた。

2.4

Later

2.5

(a) 式 (2.27) を導出せよ。

(b) 式 (2.28) を導出せよ。

(a)

$$\begin{aligned} \text{EPE}(x_0) &= \mathbb{E}_{y_0|x_0}[\mathbb{E}_{\mathcal{T}}[(y_0 - \hat{y}_0)^2]] \\ &= \mathbb{E}_{y_0|x_0}[\mathbb{E}_{\mathcal{T}}[y_0^2 - 2y_0\hat{y}_0 + \hat{y}_0^2]] \end{aligned}$$

ここで、 y_0 はトレーニングデータ \mathcal{T} には依存せず、予測値 \hat{y}_0 は真の値 y_0 には依存しないので、

$$\text{EPE}(x_0) = \mathbb{E}_{y_0|x_0}[y_0^2] - 2\mathbb{E}_{y_0|x_0}[y_0]\mathbb{E}_{\mathcal{T}}[\hat{y}_0] + \mathbb{E}_{\mathcal{T}}[\hat{y}_0^2]$$

分散と平均の関係 $\mathbb{E}(x^2) = \text{Var}(x) + \mathbb{E}(x)^2$ を用いることで、

$$\begin{aligned} \text{EPE}(x_0) &= \text{Var}(y_0|x_0) + \mathbb{E}_{y_0|x_0}[y_0]^2 + \text{Var}_{\mathcal{T}}(\hat{y}_0) + \mathbb{E}_{\mathcal{T}}[\hat{y}_0]^2 - 2\mathbb{E}_{y_0|x_0}[y_0]\mathbb{E}_{\mathcal{T}}[\hat{y}_0] \\ &= \text{Var}(y_0|x_0) + \text{Var}_{\mathcal{T}}(\hat{y}_0) + (\mathbb{E}_{y_0|x_0}[y_0] - \mathbb{E}_{\mathcal{T}}[\hat{y}_0])^2 \end{aligned}$$

ここで $\text{Var}(y_0|x_0)$ は真の値の分散 σ^2 である。

$|\mathbb{E}_{y_0|x_0}[y_0] - \mathbb{E}_{\mathcal{T}}[\hat{y}_0]|$ は Bias と呼ばれる値で、真の値の期待値 $\mathbb{E}_{y_0|x_0}[y_0]$ とモデルの予測した値の期待値 $\mathbb{E}_{\mathcal{T}}[\hat{y}_0]$ の間の乖離を示す。最小二乗推定は不偏であることが知られており、Bias は 0 になる。

以下では、 $\text{Var}_{\mathcal{T}}(\hat{y}_0)$ を計算する。

トレーニングデータ \mathcal{T} は入力 \mathbf{X} と出力 y の組み合わせとして表現できるので、 $\mathcal{T} = (\mathbf{X}, y)$ と書ける。

$$\begin{aligned}
\text{Var}_{\mathcal{T}}(\hat{y}_0) &= \mathbb{E}_{(\mathbf{X}, y)}[\hat{y}_0^2] - \mathbb{E}_{(\mathbf{X}, y)}[\hat{y}_0]^2 \\
&= \int \{\Pr(\mathbf{X}, y) \hat{y}_0^2\} d\mathbf{X} dy - \left(\int \{\Pr(\mathbf{X}, y) \hat{y}_0\} d\mathbf{X} dy \right)^2 \\
&= \int \{\Pr(\mathbf{X}) \left(\int \{\Pr(y|\mathbf{X}) \hat{y}_0^2\} dy \right)\} d\mathbf{X} - \left(\int \{\Pr(\mathbf{X}) \left(\int \{\Pr(y|\mathbf{X}) \hat{y}_0\} dy \right)\} d\mathbf{X} \right)^2 \\
&= \int \{\Pr(\mathbf{X}) \mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0^2]\} d\mathbf{X} - \left(\int \{\Pr(\mathbf{X}) \mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]\} d\mathbf{X} \right)^2 \\
&= \int \{\Pr(\mathbf{X}) (\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0) + \mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]^2)\} d\mathbf{X} - \left(\int \{\Pr(\mathbf{X}) \mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]\} d\mathbf{X} \right)^2 \\
&= \int \{\Pr(\mathbf{X}) \text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)\} d\mathbf{X} + \int \{\Pr(\mathbf{X}) \mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]^2\} d\mathbf{X} - \left(\int \{\Pr(\mathbf{X}) \mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]\} d\mathbf{X} \right)^2 \\
&= \mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)] + \mathbb{E}_{\mathbf{X}}[(\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0])^2] - (\mathbb{E}_{\mathbf{X}}[\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]])^2 \\
&= \mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)] + \text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0])
\end{aligned}$$

以下では、 $\mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)]$ と $\text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0])$ を計算していく。まず、 $\mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)]$ を展開すると

$$\begin{aligned}
\mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)] &= \mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(x_0^T \hat{\beta})] \\
&= \mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y)] \\
&= \mathbb{E}_{\mathbf{X}}[\mathbb{E}_{\Pr(y|\mathbf{X})}[(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y)^2] - (\mathbb{E}_{\Pr(y|\mathbf{X})}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y])^2] \\
&= \mathbb{E}_{\mathbf{X}}[\mathbb{E}_{\Pr(y|\mathbf{X})}[(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y)(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y)^T] \\
&\quad - (\mathbb{E}_{\Pr(y|\mathbf{X})}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y])(\mathbb{E}_{\Pr(y|\mathbf{X})}[(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y)^T])] \\
&= \mathbb{E}_{\mathbf{X}}[\mathbb{E}_{\Pr(y|\mathbf{X})}[(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y)(y^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} x_0)] \\
&\quad - (\mathbb{E}_{\Pr(y|\mathbf{X})}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y])(\mathbb{E}_{\Pr(y|\mathbf{X})}[y^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} x_0])] \\
&= \mathbb{E}_{\mathbf{X}}[(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbb{E}_{\Pr(y|\mathbf{X})}[y y^T] \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} x_0) \\
&\quad - (x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbb{E}_{\Pr(y|\mathbf{X})}[y] \mathbb{E}_{\Pr(y|\mathbf{X})}[y^T] \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} x_0)] \\
&= \mathbb{E}_{\mathbf{X}}[(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbb{E}_{\Pr(y|\mathbf{X})}[y y^T] - \mathbb{E}_{\Pr(y|\mathbf{X})}[y] \mathbb{E}_{\Pr(y|\mathbf{X})}[y^T]) \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} x_0)]
\end{aligned}$$

観測値 y_i が互いに独立で、分散 σ^2 を持つとすると $\mathbb{E}_{\Pr(y|\mathbf{X})}[y y^T] - \mathbb{E}_{\Pr(y|\mathbf{X})}[y] \mathbb{E}_{\Pr(y|\mathbf{X})}[y^T] = \sigma^2 I$ なので、

$$\begin{aligned}
\mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)] &= \mathbb{E}_{\mathbf{X}}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\sigma^2 I) \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} x_0] \\
&= \mathbb{E}_{\mathbf{X}}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} x_0 \sigma^2]
\end{aligned}$$

ここで、 $\mathcal{T} = (\mathbf{X}, y)$ であり、またカッコの中に y に依存する項目が出てこないで、

$$\mathbb{E}_{\mathbf{X}}[\text{Var}_{\Pr(y|\mathbf{X})}(\hat{y}_0)] = \mathbb{E}_{\mathbf{X}}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} x_0 \sigma^2] = \mathbb{E}_{\mathcal{T}}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} x_0 \sigma^2]$$

次に、 $\text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0])$ を計算していく。

$$\begin{aligned}
\text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]) &= \text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[x_0^T \hat{\beta}]) \\
&= \text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y]) \\
&= \text{Var}_{\mathbf{X}}(x_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \beta) \\
&= \text{Var}_{\mathbf{X}}(x_0^T \beta)
\end{aligned}$$

これは \mathbf{X} に依存しない定数なので、 $\text{Var}_{\mathbf{X}}(\mathbb{E}_{\Pr(y|\mathbf{X})}[\hat{y}_0]) = 0$

結局、 $\text{EPE}(x_0) = \sigma^2 + \mathbb{E}_{\mathcal{T}}[x_0^T (\mathbf{X}^T \mathbf{X})^{-1} x_0 \sigma^2]$ という (2.27) 式が導かれた。

(b) N が大きく \mathcal{T} がランダムに選択されており、 $\mathbb{E}_{\mathcal{T}}(X) = 0$ であるとする^{*1}。 $\mathbf{X}^T \mathbf{X} \rightarrow N \text{Cov}(X)$ となるので、

$$\begin{aligned}\mathbb{E}_{x_0}[\text{EPE}(x_0)] &= \mathbb{E}_{x_0}[x_0^T \mathbb{E}_{\mathcal{T}}[(\mathbf{X}^T \mathbf{X})^{-1}]x_0]\sigma^2 + \sigma^2 \\ &\sim \mathbb{E}_{x_0}[x_0^T (N \text{Cov}(X))^{-1}x_0]\sigma^2 + \sigma^2 \\ &= \mathbb{E}_{x_0}[x_0^T (\text{Cov}(X))^{-1}x_0]\sigma^2/N + \sigma^2\end{aligned}$$

トレース演算の巡回性 [$\text{trace}(AB) = \text{trace}(BA)$] および線形性により

$$\begin{aligned}\mathbb{E}_{x_0}[\text{EPE}(x_0)] &\sim \text{trace}[\mathbb{E}_{x_0}[x_0^T (\text{Cov}(X))^{-1}x_0]]\sigma^2/N + \sigma^2 \\ &= \mathbb{E}_{x_0}[\text{trace}[x_0^T (\text{Cov}(X))^{-1}x_0]]\sigma^2/N + \sigma^2 \\ &= \mathbb{E}_{x_0}[\text{trace}[(\text{Cov}(X))^{-1}x_0x_0^T]]\sigma^2/N + \sigma^2 \\ &= \text{trace}[(\text{Cov}(X))^{-1}\mathbb{E}_{x_0}[x_0x_0^T]]\sigma^2/N + \sigma^2\end{aligned}$$

$\mathbb{E}_{\mathcal{T}}[X] = 0$ より $\mathbb{E}_{x_0}[x_0] = 0$ である。 $\mathbb{E}_{x_0}[x_0x_0^T] = \mathbb{E}_{x_0}[(x_0 - \mathbb{E}_{x_0}[x_0])(x_0 - \mathbb{E}_{x_0}[x_0])^T] = \text{Cov}(x_0)$ となるので、

$$\begin{aligned}\mathbb{E}_{x_0}[\text{EPE}(x_0)] &\sim \text{trace}[(\text{Cov}(X))^{-1}\text{Cov}(x_0)]\sigma^2/N + \sigma^2 \\ &= \text{trace}[(\text{Cov}(X))^{-1}\text{Cov}(x_0)]\sigma^2/N + \sigma^2 \\ &= \text{trace}[\mathbf{I}]\sigma^2/N + \sigma^2 \\ &= p\sigma^2/N + \sigma^2\end{aligned}$$

以上により、式 (2.28) が導かれた。

2.6

Later

2.7

Later

2.8

Later

2.9

$$\begin{aligned}\mathbb{E}_{\{X,y\}}[R_{\text{tr}}(\hat{\beta})] &= \mathbb{E}_{\{X,y\}}[\min_{\beta} R_{\text{tr}}(\beta)] \\ &\leq \min_{\beta} \mathbb{E}_{\{X,y\}}[R_{\text{tr}}(\beta)] \\ &= \min_{\beta} \mathbb{E}_{\{\hat{X},\hat{y}\}}[R_{\text{te}}(\beta)] \\ &\leq \mathbb{E}_{\{\hat{X},\hat{y}\}}[R_{\text{te}}(\hat{\beta})]\end{aligned}$$

^{*1} \mathbf{X} は観測された値を行とする行列を表しており、 X は一つの観測値の確率変数を表す。 X は p 次元のベクトル。

上記のそれぞれの等号や不等号の変形を証明すれば良い。

1. $\mathbb{E}_{\{X,y\}}[R_{\text{tr}}(\hat{\beta})] = \mathbb{E}_{\{X,y\}}[\min_{\beta} R_{\text{tr}}(\beta)]$ は最小 2 乗法の定義より成り立つ。
2. それぞれの値を β で最小化してから期待値 (平均値) を取った方が、平均値を取った後に β で最小化するよりも小さいか等しくなるので、 $\mathbb{E}_{\{X,y\}}[\min_{\beta} R_{\text{tr}}(\beta)] \leq \min_{\beta} \mathbb{E}_{\{X,y\}}[R_{\text{tr}}(\beta)]$ が成り立つ。
- 3.

$$\begin{aligned} \min_{\beta} \mathbb{E}_{\{X,y\}}[R_{\text{tr}}(\beta)] &= \min_{\beta} \mathbb{E}_{\{X,y\}}\left[\frac{1}{N} \sum_{i=1}^N (y_i - \beta^T x_i)^2\right] \\ &= \min_{\beta} \mathbb{E}_{\{x,y\}}[(y - \beta^T x)^2] \\ &= \min_{\beta} \mathbb{E}_{\{\tilde{x}, \tilde{y}\}}[(\tilde{y} - \beta^T \tilde{x})^2] \\ &= \min_{\beta} \mathbb{E}_{\{\tilde{X}, \tilde{y}\}}\left[\frac{1}{M} \sum_{i=1}^M (\tilde{y}_i - \beta^T \tilde{x}_i)^2\right] \\ &= \min_{\beta} \mathbb{E}_{\{\tilde{X}, \tilde{y}\}}[R_{\text{te}}(\beta)] \end{aligned}$$

より $\min_{\beta} \mathbb{E}_{\{X,y\}}[R_{\text{tr}}(\beta)] = \min_{\beta} \mathbb{E}_{\{\tilde{X}, \tilde{y}\}}[R_{\text{te}}(\beta)]$ が成り立つ。

4. \min_{β} という関数の定義から $\min_{\beta} \mathbb{E}_{\{\tilde{X}, \tilde{y}\}}[R_{\text{te}}(\beta)] \leq \mathbb{E}_{\{\tilde{X}, \tilde{y}\}}[R_{\text{te}}(\hat{\beta})]$ が成り立つ。

3 回帰のための線形手法

Later

4 分類のための線形手法

Later

5 基底展開と正則化

5.1

式 (5.3) 中の切断べき基底関数が、文中で述べられていたような二つの節点を持つ 3 次スプラインの基底を表すことを示せ。

まず、 $h_1(X) = 1$, $h_2(X) = X$, $h_3(X) = X^2$, $h_4(X) = X^3$, $h_5(X) = (X - \xi_1)_+^3$, $h_6(X) = (X - \xi_2)_+^3$ と定義すると、任意の β_m ($m = 1, 2, \dots, 6$) に対して、 $f(X) = \sum_{m=1}^6 \beta_m h_m(X)$ とその 1 階導関数、および 2 階導関数がそれぞれ連続になることを示す。そのためには、各 i に対して関数 h_i とその 1 階導関数、2 階導関数がそれぞれ連続になることを示せば十分。 h_1, h_2, h_3, h_4 は明らかに無限回微分可能である。 h_5 が $X = \xi_1$ 以外の点で連続であることは明らかである。よって、 $X = \xi_1$ の点で、 h_5 , h'_5 , h''_5 がそれぞれ連続であることを確かめる。

$$\begin{aligned} \lim_{X \rightarrow \xi_1+0} h_5(X) &= \lim_{X \rightarrow \xi_1+0} (X - \xi_1)^3 = 0 \\ \lim_{X \rightarrow \xi_1-0} h_5(X) &= \lim_{X \rightarrow \xi_1-0} 0 = 0 \end{aligned}$$

よって、 $h_5(X)$ は $X = \xi_1$ で連続である。また、

$$\lim_{X \rightarrow \xi_1+0} h'_5(X) = \lim_{X \rightarrow \xi_1+0} 3(X - \xi_1)^2 = 0$$

$$\lim_{X \rightarrow \xi_1 - 0} h'_5(X) = \lim_{X \rightarrow \xi_1 - 0} 0 = 0$$

よって、 $h'_5(X)$ は $X = \xi_1$ で連続である。さらに、

$$\lim_{X \rightarrow \xi_1 + 0} h''_5(X) = \lim_{X \rightarrow \xi_1 + 0} 6(X - \xi_1) = 0$$

$$\lim_{X \rightarrow \xi_1 - 0} h''_5(X) = \lim_{X \rightarrow \xi_1 - 0} 0 = 0$$

よって、 $h''_5(X)$ も $X = \xi_1$ の点で連続である。同様に h_6 , h'_6 , h''_6 の連続性も証明できる。以上より、 $f(X)$ とその 1 階導関数、および 2 階導関数がそれぞれ連続になり、3 次スプラインの条件を満たす。

次に、このように定義された f が 3 次スプラインの基底であることを確かめる。 $h_1, h_2, h_3, h_4, h_5, h_6$ が 1 次独立であることは明らかである^{*2}。よって、3 次スプラインの条件を満たす任意の関数 $g(X)$ が $f(X) = \sum_{m=1}^M \beta_m h_m(X)$ の形で表現できることを示せば十分である。3 次関数 $g : (\xi_0, \xi_3) \rightarrow \mathbb{R}$ が 3 次関数 g_1, g_2, g_3 を用いて各領域ごとに以下のように定義されるとしても g は一般性を失わない。

$$g(X) = \begin{cases} g_1(X) & (\xi_0 \leq X \leq \xi_1) \\ g_1(X) + g_2(X) & (\xi_1 \leq X \leq \xi_2) \\ g_1(X) + g_2(X) + g_3(X) & (\xi_2 \leq X \leq \xi_3) \end{cases}$$

このとき、 $g(X)$ の連続性により、 $g_2(\xi_1) = 0$, $g_3(\xi_2) = 0$ が成り立つ。よって、

$$\begin{aligned} g_1(X) &= aX^3 + bX^2 + cX + d \\ g_2(X) &= e(X - \xi_1)(X^2 + hX + i) \\ g_3(X) &= j(X - \xi_2)(X^2 + kX + l) \end{aligned}$$

と表現できるはずである。さらに、 $g'(X)$ の連続性により、 $g'_2(\xi_1) = 0$, $g'_3(\xi_2) = 0$ が成り立つはずなので、 $e = 0$ または $\xi_1^2 + h\xi_1 + i = 0$ が成り立ち、さらに $j = 0$ または $\xi_2^2 + k\xi_2 + l = 0$ が成り立つ。よって、

$$\begin{aligned} g_1(X) &= aX^3 + bX^2 + cX + d \\ g_2(X) &= e(X - \xi_1)^2(X + m) \\ g_3(X) &= j(X - \xi_2)^2(X + n) \end{aligned}$$

と表現できることがわかった。さらに、 $g''(X)$ の連続性により、 $g''_2(\xi_1) = 0$, $g''_3(\xi_2) = 0$ が成り立つはずなので、 $e = 0$ または $\xi_1 + m = 0$ が成り立ち、さらに $j = 0$ または $\xi_2 + n = 0$ が成り立つ。結局、

$$\begin{aligned} g_1(X) &= aX^3 + bX^2 + cX + d \\ g_2(X) &= e(X - \xi_1)^3 \\ g_3(X) &= j(X - \xi_2)^3 \end{aligned}$$

と表現できることになり、この $g(X)$ は関数 $f(X)$ と同じ形になった。以上より、関数 f の形で任意の 3 次スプライン関数が表現できることになり、関数 h_1, \dots, h_6 は 3 次スプラインの基底であることがわかった。

^{*2} $\{h_n\}_{n=1}^6$ の中のどの元も残りの元の線型結合で表現できない。